

Análise comparativa de métricas de avaliação em modelos de aprendizado de máquina na detecção de ataques de spoofing de GPS

Ana Carla Rodrigues¹, Jessica Fileto¹

¹ Centro de Matemática, Computação e Cognição
Universidade Federal do ABC (UFABC)
Av. dos Estados, 5001 – 09210-580 – Santo André – SP – Brasil

{carla.rodrigues, jessica.fileto}@ufabc.edu.br

Resumo. O Veículo Aéreo Não Tripulado (VANT), comumente conhecido como drone, é uma plataforma que está revolucionando indústrias ao redor do mundo, oferecendo soluções de alta flexibilidade e riscos reduzidos. O Global Positioning System (GPS) fornece ao VANT navegação precisa, rastreamento e voo autônomo. Os VANTs podem sofrer ataques de spoofing nas coordenadas de GPS, comprometendo a segurança da informação e demonstrando que a precisão na análise dos dados são cruciais na tomada de decisões. A inteligência artificial pode ser uma aliada na detecção destes ataques através de técnicas sofisticadas, reduzindo a quantidade de falsos alarmes e fornecendo informações confiáveis por meio do aprendizado de máquina que exerce papel fundamental na classificação destes ataques. A proposta deste projeto é realizar uma análise comparativa das métricas de avaliação dos seguintes modelos de aprendizado de máquina: Random Forest, Naive Bayes, K-NN, Gaussian Naive Bayes e Extremely Randomized Trees, visando identificar aquele que melhor equilibre a detecção correta de spoofing e viabilidade de implementação do modelo.

1. Introdução

Os veículos aéreos não tripulados (VANTS), também conhecidos como drone, são um tipo de tecnologia fundamental tanto em áreas civis quanto militares. Seu uso reduz a exposição humana a tarefas repetitivas, de longa duração e em alguns casos, de alto risco [Brasil 2025]. Desempenham papel importante nas seguintes áreas: gerenciamento de desastres, vigilância aérea, fotografia aérea de rastreamento, pesquisa e resgate, monitoramento de gado, dentre outros. [Titouna e Näit-Abdesselam 2021]

Por serem operados de maneira autônoma e remota suas coordenadas são essenciais para o sucesso de suas missões, para isso são usados sinais de Sistema Global de Navegação por Satélite (GNSS), sendo o mais conhecido o *Global Positioning System* (GPS), esses sinais podem ser criptografados ou não [A. Faria1 et al. 2018]. Sendo os não criptografados mais suscetíveis a ataques conhecidos como *Spoofing* de GPS [Srinivasan S e Sathyadevan 2023].

Para garantir um voo seguro do VANT é essencial ter medidas para detecção dos ataques de *Spoofing de GPS*. A identificação precisa desses ataques é extremamente importante, pois técnicas avançadas de *spoofing* podem causar disrupção no funcionamento do VANT, portanto são necessários métodos robustos e adaptativos [İşleyen e Bahtiyar

2024]. Nesse contexto algoritmos de aprendizado de máquina tem se mostrado promissores, pois são capazes de analisar grandes volumetrias de dados, identificando padrões e anomalias. Tais abordagens oferecem uma resposta robusta e adaptativa a essas ameaças contribuindo para as operações dos VANTs [İşleyen e Bahtiyar 2024].

2. Trabalhos relacionados

Diversos estudos recentes tem utilizado essa abordagem para detecção de *spoofing* de GPS. Podemos mencionar algumas abordagens utilizadas:

- **Redes neurais profundas (DNN):** Extração de padrões complexos em séries temporais dos sinais GNSS. [İşleyen e Bahtiyar 2024]
- **Máquinas de vetores de suporte (SVM):**
Abordagem teve como objetivo a identificação de discrepâncias entre as posições determinadas pelos sinais de GPS e aquelas medidas pelo sistema de navegação inercial (INS). Especificamente, o modelo SVM foi treinado através dos erros obtidos das diferenças posicionais, permitindo que o sistema detecte inconsistências que poderiam indicar um ataque de *spoofing* de GPS. [Panice et al. 2017]
- **Redes neurais convolucionais (CNN):** Em comparação aos modelos tradicionais de aprendizagem de máquina, os de aprendizagem profunda obtiveram alta acurácia na detecção dos ataques de *spoofing*. A grande vantagem desses modelos baseados em aprendizagem profunda, é pelo fato de aprenderem automaticamente a extraírem as *features* sem precisarem de intervenção humana. Além de se adaptarem melhor a *datasets* mais complexos. [Sun et al. 2023]
- **Aprendizagem supervisionada (Baseado em Árvores):** Aissou et al. (2021) utilizou os seguintes modelos baseados em árvores: Random Forest, Gradient Boost, XGBoost e LightGBM para fazer um comparativo de qual seria melhor na detecção dos ataques de *spoofing* de GPS. Sendo que o XGBoost obteve a melhor acurácia (95,52%).
- **IA Generativa:** Abordagem que em comparação com outros modelos de aprendizagem de máquina, se destacou pela eficácia na detecção dos ataques de *spoofing* e *jamming*. [El alami e Rawat 2024]

3. Delimitação e Escopo

O *dataset* que será utilizado como base de dados é o *Mendeley Data* [Aissou 2022], esses dados foram gerados de sinais GPS autênticos e contém aproximadamente 500,000 dados, no artigo escolhido de [Aissou et al. 2021] não possui uma citação do *dataset* usado para o treinamento dos modelos, então para as análises decorrentes deste artigo será utilizada essa fonte de dados simplificada e disponibilizada pelos autores do artigo. De acordo com o artigo de [Aissou et al. 2021], os ataques do tipo *spoofing* podem ser classificados em: simples, intermediários e sofisticados.

Nas próximas seções se estabelecerá a execução do trabalho. Na seção 4, faremos nossa proposta de mudança ao trabalho de [Aissou et al. 2021], discutindo a metodologia e modelos de aprendizado de máquina a serem implementados. Logo, os resultados e discussões serão apresentados na seção 5. Finalmente, nossas conclusões sobre o trabalho serão expostos na seção 6.

4. Metodologia (Proposta de mudança)

A metodologia adotada e os passos seguidos foram inspirados no artigo de [Aissou et al. 2021], que utilizou a implementações de algoritmos como: *Random Forest*, *Gradient Boost*, *XGBoost*, e *LightGBM* com o objetivo de explorar os dados obtidos.

A proposta de mudança deste artigo é avaliar outros modelos para a classificação de possíveis ataques de *spoofing* a sinais de GPS, com enfoque em algoritmos que não são baseados em árvore, sendo estes: (i) *Naive Bayes*, (ii) *K-NN* e (iii) *Gaussian Naive Bayes*.

Além da reimplementação do algoritmo (iv) *Random Forest* que foi utilizado no artigo [Aissou et al. 2021] e obteve o pior desempenho no comparativo. Com base no desempenho do *Random Forest*, será feita a implementação do algoritmo (v) *Extremely randomized trees*, um modelo melhorado do *Random Forest*, que se diferem pelo fato de no *Extremely randomized trees* não existir a fase de *bagging* e no momento da separação dos nós, esta escolha é feita aleatoriamente. **geurtsExtremelyRandomizedTrees2006**

Serão analisados a acurácia, precisão e a quantidade de falsos negativos. Para isso a base será dividida em porções diferentes para testes e o treinamento do modelo, sendo 70% para treino e 30% para testes como no artigo de [Aissou et al. 2021].

Será aplicada a técnica de pré processamento *Principal Component Analysis* (PCA) para melhorar a precisão dos resultados finais, ela consiste em reduzir as dimensões do dataset para deixar apenas as informações mais importantes, removendo assim as redundâncias [IBM 2025]. Esse tipo de processamento ajuda algoritmos de aprendizagem de máquina, simplificando o processo de reconhecimento dos dados, essa técnica é diferente da usada no artigo de [Aissou et al. 2021] que se chama *Spearman Correlation Coefficient*.

Referências

- A. Faria1, Lester de et al. (2018). “GPS Jamming Signals Propagation in Free-Space, Urban and Suburban Environments”. Em: *Journal Aerospace Technology Management*. DOI: 10.5028/jatm.v10.870.
- Aissou, Ghilas (2022). *A DATASET for GPS Spoofing Detection on Unmanned Aerial System*. Mendeley Data, V3. DOI: 10.17632/z7dj3yyzt8.3.
- Aissou, Ghilas et al. (2021). “Tree-based Supervised Machine Learning Models For Detecting GPS Spoofing Attacks on UAS”. Em: *2021 IEEE 12th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON)*, pp. 0649–0653. DOI: 10.1109/UEMCON53757.2021.9666744.
- Brasil, Dialogos Uniao Europeia (2025). *Estudo sobre a Indústria Brasileira e Europeia de Veículos aéreos não tripulados*. Rel. técn. Dialogos Uniao Europeia Brasil. DOI: https://www.gov.br/mdic/pt-br/images/publicacaoa_DRONES-20161130-20012017-web.pdf.
- El alami, Hassan e Danda B. Rawat (2024). “DroneDefGANt: A Generative AI-Based Approach for Detecting UAS Attacks and Faults”. Em: *ICC 2024 - IEEE International Conference on Communications*, pp. 1933–1938. DOI: 10.1109/ICC51166.2024.10622524. (Acesso em 23/07/2025).
- IBM (2025). *What is principal component analysis (PCA)?* URL: <https://www.ibm.com/think/topics/principal-component-analysis> (acesso em 31/07/2025).

- İşleyen, Emre e Şerif Bahtiyar (2024). “GPS Spoofing Detection on Autonomous Vehicles with XGBoost”. Em: *2024 9th International Conference on Computer Science and Engineering (UBMK)*, pp. 500–505. DOI: 10.1109/UBMK63289.2024.10773593. (Acesso em 23/07/2025).
- Panice, G. et al. (2017). “A SVM-based detection approach for GPS spoofing attacks to UAV”. Em: *2017 23rd International Conference on Automation and Computing (ICAC)*, pp. 1–11. DOI: 10.23919/IConAC.2017.8081999.
- Srinivasan S, Prasanna e Shiju Sathyadevan (2023). “GPS Spoofing Detection in UAV Using Motion Processing Unit”. Em: *2023 11th International Symposium on Digital Forensics and Security (ISDFS)*, pp. 1–4. DOI: 10.1109/ISDFS58141.2023.10131729. (Acesso em 23/07/2025).
- Sun, Yichen et al. (2023). “A Deep-Learning-Based GPS Signal Spoofing Detection Method for Small UAVs”. Em: *Drones* 7.6. ISSN: 2504-446X. DOI: 10.3390/drones7060370. URL: <https://www.mdpi.com/2504-446X/7/6/370>.
- Titouna, Chafiq e Farid Naït-Abdesselam (2021). “A Lightweight Security Technique For Unmanned Aerial Vehicles Against GPS Spoofing Attack”. Em: *2021 International Wireless Communications and Mobile Computing (IWCMC)*, pp. 819–824. DOI: 10.1109/IWCMC51323.2021.9498734. (Acesso em 23/07/2025).