

Análise comparativa de métricas de avaliação em modelos de aprendizado de máquina na detecção de ataques de spoofing de GPS

Ana Carla Rodrigues¹, Jessica Fileto¹

¹ Centro de Matemática, Computação e Cognição
Universidade Federal do ABC (UFABC)
Av. dos Estados, 5001 – 09210-580 – Santo André – SP – Brasil

{carla.rodrigues, jessica.fileto}@ufabc.edu.br

Resumo. *O Veículo Aéreo Não Tripulado (VANT), comumente conhecido como drone, é uma plataforma que está revolucionando indústrias ao redor do mundo, oferecendo soluções de alta flexibilidade e riscos reduzidos. O Global Positioning System (GPS) fornece ao VANT navegação precisa, rastreamento e voo autônomo. Os VANTs podem sofrer ataques de spoofing nas coordenadas de GPS, comprometendo a segurança da informação e demonstrando que a precisão na análise dos dados são cruciais na tomada de decisões. A inteligência artificial pode ser uma aliada na detecção destes ataques através de técnicas sofisticadas, reduzindo a quantidade de falsos alarmes e fornecendo informações confiáveis por meio do aprendizado de máquina que exerce papel fundamental na classificação destes ataques. A proposta deste projeto é realizar uma análise comparativa das métricas de avaliação dos seguintes modelos de aprendizado de máquina: Random Forest, XGBoost, SVM, K-NN, Gaussian Naive Bayes e Extremely Randomized Trees, visando identificar aquele que melhor equilibre a detecção correta de spoofing e viabilidade de implementação do modelo.*

1. Introdução

Os veículos aéreos não tripulados (VANTS), também conhecidos como drones, são um tipo de tecnologia fundamental tanto em áreas civis quanto militares. Seu uso reduz a exposição humana a tarefas repetitivas, de longa duração e em alguns casos, de alto risco [Brasil 2025]. Desempenham papel importante nas seguintes áreas: gerenciamento de desastres, vigilância aérea, fotografia aérea de rastreamento, pesquisa e resgate, monitoramento de gado, dentre outros. [Titouna e Naït-Abdesselam 2021]

Por serem operados de maneira autônoma e remota suas coordenadas são essenciais para o sucesso de suas missões, para isso são usados sinais de Sistema Global de Navegação por Satélite (GNSS), sendo o mais conhecido o *Global Positioning System* (GPS), esses sinais podem ser criptografados ou não [A. Faria1 et al. 2018]. Sendo os não criptografados mais suscetíveis a ataques conhecidos como *Spoofing* de GPS [Srinivasan S e Sathyadevan 2023].

O ataque de *spoofing* de GPS é caracterizado por um atacante que faz uso de antenas terrestres emitindo sinais falsos. [Jafarnia-Jahromi, Broumandan e Nielsen 2012] Estes ataques são classificados em: simples, intermediários e sofisticados [Aissou et al. 2021].

Para garantir um voo seguro do VANT é essencial ter medidas para detecção dos ataques de *Spoofing de GPS*. A identificação precisa desses ataques é extremamente importante, pois técnicas sofisticadas de *spoofing* podem causar disrupção no funcionamento do VANT, portanto são necessários métodos robustos e adaptativos [İşleyen e Bahtiyar 2024]. Nesse contexto algoritmos de aprendizado de máquina tem se mostrado promissores, pois são capazes de analisar grandes volumetrias de dados, identificando padrões e anomalias. Tais abordagens oferecem uma resposta robusta e adaptativa a essas ameaças contribuindo para as operações dos VANTs [İşleyen e Bahtiyar 2024].

Neste trabalho será feita a reimplementação dos algoritmos *RandomForest* e *XGBoost* e seus respectivos experimentos do artigo [Aissou et al. 2021], com o objetivo de comparar esses algoritmos com outros que não são baseados em árvore, sendo eles: *Support Vector Machines* (SVM), *K-NN*, *Gaussian Naive Bayes* e *Extremely Randomized Trees*.

2. Trabalhos relacionados

Diversos estudos recentes tem utilizado aprendizado de máquina para detecção de ataques de *spoofing* de GPS. Podemos mencionar algumas abordagens utilizadas:

- **Redes neurais profundas (DNN):** Extração de padrões complexos em séries temporais dos sinais GNSS. [İşleyen e Bahtiyar 2024]
- **Máquinas de vetores de suporte (SVM):**
Abordagem teve como objetivo a identificação de discrepâncias entre as posições determinadas pelos sinais de GPS e aquelas medidas pelo sistema de navegação inercial (INS). Especificamente, o modelo SVM foi treinado através dos erros obtidos das diferenças posicionais, permitindo que o sistema detecte inconsistências que poderiam indicar um ataque de *spoofing* de GPS. [Panice et al. 2017]
- **Redes neurais convolucionais (CNN):** Em comparação aos modelos tradicionais de aprendizagem de máquina, os de aprendizagem profunda obtiveram alta acurácia na detecção dos ataques de *spoofing*. A grande vantagem desses modelos baseados em aprendizagem profunda, é pelo fato de aprenderem automaticamente a extraírem as *features* sem precisarem de intervenção humana. Além de se adaptarem melhor a *datasets* mais complexos. [Sun et al. 2023]
- **Aprendizagem supervisionada (Baseado em Árvores):** Aissou et al. (2021) utilizou os seguintes modelos baseados em árvores: Random Forest, Gradient Boost, XGBoost e LightGBM para fazer um comparativo de qual seria melhor na detecção dos ataques de *spoofing* de GPS. Sendo que o XGBoost obteve a melhor acurácia (95,52%).
- **IA Generativa:** Abordagem que em comparação com outros modelos de aprendizagem de máquina, se destacou pela eficácia na detecção dos ataques de *spoofing* e *jamming*. [El alami e Rawat 2024]

3. Delimitação e Escopo

O artigo [Aissou et al. 2021] não cita o *dataset* usado para o treinamento dos modelos, então para as análises decorrentes deste artigo será utilizado o *Mendeley Data* [Aissou 2022], que foi disponibilizado pelos autores do artigo. Esse *dataset* é uma versão simplificada, pois é representada em duas dimensões. Esses dados foram gerados de sinais GPS autênticos e contém aproximadamente 500,000 dados.

Nas próximas seções se estabelecerá a execução do trabalho. Na seção 4, faremos nossa proposta de mudança ao trabalho de [Aissou et al. 2021], discutindo a metodologia e modelos de aprendizado de máquina a serem implementados. Logo, os resultados e discussões serão apresentados na seção 5. Finalmente, nossas conclusões sobre o trabalho serão expostos na seção 6.

4. Metodologia

A metodologia adotada e os passos seguidos foram inspirados no artigo de [Aissou et al. 2021], que implementou os algoritmos baseados em árvore: *Random Forest*, *Gradient Boost*, *XGBoost* e *LightGBM* com o objetivo de explorar os dados obtidos.

Será realizada a reimplementação dos algoritmos (i) *Random Forest* e (ii) *XGBoost*, ambos obtiveram o pior e melhor desempenho, respectivamente, ponderando as métricas de tempo de execução e uso de memória, no comparativo dos modelos baseados em árvore. Ambos algoritmos serão comparados com outros modelos que não são baseados em árvore, sendo eles: (iii) SVM, (iv) *K-NN* e (v) *Gaussian Naive Bayes*.

Será incluído o modelo baseado em árvore conhecido como (vi) *Extremely randomized trees* que é um modelo melhorado do *Random Forest*, que se difere pelo fato que no *Extremely randomized trees* não existe a fase de *bagging* e no momento da separação dos nós, esta escolha é feita aleatoriamente [Geurts, Ernst e Wehenkel 2006].

Será feita a análise comparativa entre os algoritmos baseados em árvore e os demais algoritmos, com o objetivo de identificar aquele que melhor equilibre a detecção correta de *spoofing* e viabilidade de implementação do modelo. Também ocorrerá a análise entre os modelos baseados em árvore para averiguar se o *Extremely Randomized Trees* obtém um desempenho melhor que o *Random Forest*. O algoritmo *XGBoost* será mantido, pois obteve o melhor desempenho no artigo de [Aissou et al. 2021]. Portanto ele será usado como base para comparação com os demais algoritmos.

Para a avaliação do desempenho dos modelos será utilizada a biblioteca *PyCM* do Python, que é uma biblioteca de matriz de confusão multiclasse, que implementa diversas métricas de classificação. [Haghighi et al. 2018]

Serão analisadas a acurácia, precisão e a quantidade de falsos negativos. Além disso, será feita a análise do tempo de treinamento, predição e uso de memória de cada modelo, com o objetivo de identificar o mais viável para implementação em VANTs.

4.1. Divisão dos dados

A base será dividida em porções diferentes para testes e o treinamento do modelo, sendo 70% para treino e 30% para testes conforme realizado no artigo. [Aissou et al. 2021]

4.2. Matthews Correlation Coefficient (MCC)

O *Matthews Correlation Coefficient* (MCC) é uma métrica de avaliação de modelos de classificação binária, que posteriormente foi extrapolada para classificação multiclasse. [Jurman, Riccadonna e Furlanello 2012]

Neste trabalho será utilizado o MCC, juntamente com a acurácia para avaliar a eficácia dos modelos de aprendizado de máquina na detecção de ataques de *spoofing* de GPS.

4.3. Pré-Processamento dos dados

Será aplicada a técnica de pré processamento *Principal Component Analysis* (PCA) para melhorar a precisão dos resultados finais. Ela consiste em reduzir a dimensão do dataset para deixar apenas as informações mais relevantes, removendo assim as redundâncias [Pearson 1901]. Assim como serão utilizadas outras duas técnicas adicionais conhecidas como *Standard Scaler* para melhorar o desempenho do processamento [Pearson 1894] e o *Random Under Sampler* para reduzir o desbalanceamento das classes que dificultam o treinamento e a análise dos dados [Japkowicz 2000].

Essas técnicas são diferentes da usada no artigo de [Aissou et al. 2021] que se chama *Spearman Correlation Coefficient*.

4.4. Análise do desempenho

Para analisar a eficácia do algoritmo através dos dados disponíveis é necessário avaliar os comportamentos dos modelos e para isso serão utilizadas as seguintes métricas: (i) probabilidade de detecção, (ii) acurácia, (iii) probabilidade de detecção falsa, (iv) probabilidade de alarme falso, (v) taxa de erro, (vi) coeficiente MCC, (vii) F1 score, (viii) especificidade.

5. Resultados e discussões

Com base nos dados da Tabela 1 podemos avaliar o desempenho dos algoritmos utilizados para classificar ataques de *spoofing* aos VANTS.

Tabela 1. Métricas de desempenho

Métrica	Random Forest	Extremely Randomized Trees	XGBoost	KNN	Gaussian Naive Bayes	SVM
Probabilidade de detecção	90.76%	89.71%	74.31%	73.32%	46.21%	37.68%
Acurácia	93.51%	92.65%	79.29%	78.96%	58.31%	53.25%
Probabilidade de detecção falsa	9.24%	10.29%	25.69%	26.68%	53.79%	62.32%
Probabilidade de alarme falso	1.63%	1.74%	3.79%	5.37%	26.45%	15.95%
Taxa de Erro	6.49%	7.35%	20.71%	21.04%	41.69%	46.75%
Coeficiente MCC	0.81	0.79	0.57	0.55	0.16	0.18
F1-Score	0.91	0.90	0.77	0.76	0.53	0.45
Especificidade	0.98	0.98	0.96	0.95	0.74	0.84

5.1. Probabilidade de detecção

Os algoritmos com a maior probabilidade de detecção foram o *Random Forest* (90.76%) e o *Extremely Randomized Trees* (89.71%), enquanto os que apresentaram pior desempenho foram o *SVM* (37.68%) e o *Gaussian Naive Bayes* (46.21%). A figura 1 mostra a probabilidade de detecção e a acurácia dos modelos.

5.2. Acurácia

A acurácia do *Random Forest* foi de 93.51%, seguido pelo *Extremely Randomized Trees* com 92.65%, enquanto o *XGBoost* obteve 79.29% e o *SVM* 53.25%. Esses resultados indicam que o *Random Forest* e o *Extremely Randomized Trees* são os mais eficazes na detecção de ataques de *spoofing*. O *XGBoost* obteve uma acurácia inferior ao *Random Forest*, o que indica que as técnicas de pré-processamento não foram eficazes para esse algoritmo. O *SVM* obteve a menor acurácia, indicando que não é adequado para a detecção de ataques de *spoofing*.

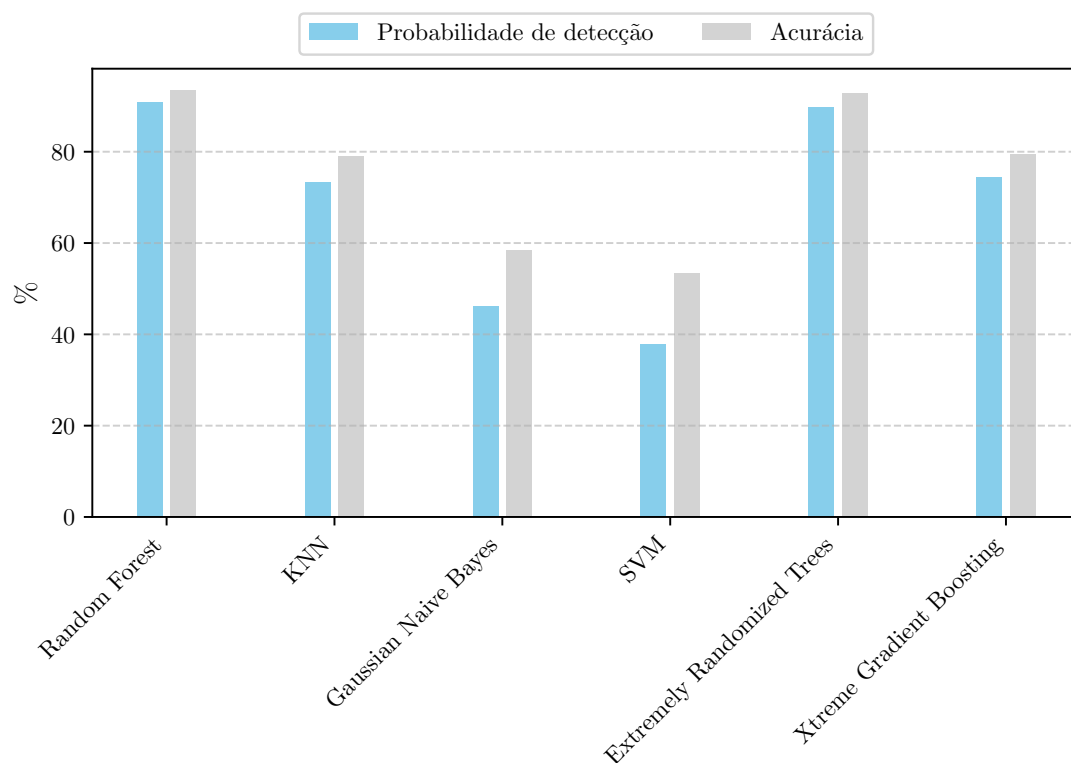


Figura 1. Gráfico de probabilidade de detecção e acurácia.

5.3. Probabilidade de detecção falsa

Os algoritmos que não são baseados em árvore obtiveram as maiores probabilidades de detecção falsa, sendo o *Gaussian Naive Bayes* (53.79%) e o *SVM* (62.32%). Esses resultados indicam que os algoritmos não baseados em árvore são ineficazes na detecção de ataques de *spoofing*.

5.4. Probabilidade de alarme falso

O *Random Forest* obteve a menor probabilidade de alarme falso (1.63%). Em comparação com o estudo de [Aissou et al. 2021], na qual obteve uma probabilidade de alarme falso de (8.53%), o *Random Forest* obteve uma melhora significativa. Possivelmente devido as técnicas de pré-processamento implementadas neste trabalho.

A figura 2 mostra a probabilidade de detecção falsa e alarme falso dos modelos.

5.5. Taxa de erro

Os algoritmos com a menor taxa de erros são: *Random Forest* (6.49%) e o *Extremely Randomized Trees* (7.35%), enquanto os que apresentaram pior performance foram *SVM* (46.75%) e *Gaussian Naive Bayes* (41.66%).

5.6. Coeficiente MCC

O *Random Forest* apresentou o maior MCC (0.81) provando ser confiável na detecção, enquanto o *SVM* o pior (0.45).




Figura 2. Gráfico de probabilidade de detecção falsa e alarme falso.

5.7. F1 score

Novamente o *Random Forest* (0.91) e o *Extremely Randomized Trees* (0.90) provaram sua eficácia, e SVM (0.45) como pior na avaliação de recall e precisão.

5.8. Especificidade

O *Random Forest* tem a maior especificidade prevendo um verdadeiro negativo para cada categoria disponível (0.98) e o menor SVM (0.84).

5.9. Métricas de performance

Com base na Tabela 2 podemos avaliar as métricas de performance dos modelos de aprendizado de máquina.

Tabela 2. Métricas de performance dos modelos

Algoritmo	Tempo de treinamento	Uso de memória (treinamento)	Tempo de predição	Uso de memória (predição)
Gaussian Naive Bayes	209.44 ms	8.92 MiB	48.67 ms	33.95 MiB
KNN	335.34 ms	4.18 MiB	9129.37 ms	25.39 MiB
SVM	772.69 ms	1.45 MiB	15.19 ms	9.41 MiB
Extremely Randomized Trees	6180.53 ms	10.12 MiB	2237.85 ms	18.13 MiB
Random Forest	43128.56 ms	11.84 MiB	1475.68 ms	18.13 MiB
Xtreme Gradient Boosting	229203.56 ms	18.13 MiB	793.14 ms	23.96 MiB

Os algoritmos que não são baseados em árvore, foram os que apresentaram melhores métricas de performance, com destaque para o *Gaussian Naive Bayes* que obteve o

menor tempo de treinamento (209.44 ms), e o *SVM* que obteve o menor uso de memória no treino e na predição (1.45 MiB e 9.41 MiB), além de ser o mais rápido na predição (15.19 ms). Apesar da boa performance em tempo de execução e uso de memória, as métricas de desempenho foram ruins, com alta taxa de erro (41.69% e 46.75%) e baixa acurácia (58.31% e 53.25%).

6. Conclusão

Neste trabalho foi realizada a análise de diferentes algoritmos de aprendizagem de máquina para detectar ataques do tipo *spoofing* a sinais de GPS em VANTs.

Dentre os algoritmos implementados o que apresentou as melhores métricas de desempenho foi o *Random Forest*. Em relação as métricas de performance, o *Random Forest* obtém melhores resultados que o *XGBoost* nos aspectos de tempo de treinamento (43128.56 ms) e uso de memória (18.13 MiB), porém o *XGBoost* ainda é mais rápido na predição (793.14 ms).

Os demais algoritmos que não são baseados em árvore, *SVM* e *Gaussian Naive Bayes* apresentaram resultados ruins, com altas taxas de erro (46.75% e 41.69% respectivamente), e baixa acurácia (53.25% e 58.31% respectivamente). O *K-NN* também não se destacou, com taxa de erro de 21.04% e acurácia de 78.96%. Apesar de sua acurácia estar próxima ao *XGBoost*, as probabilidades de detecção falsa e alarme falso foram altas (26.68% e 5.37% respectivamente). Esses resultados indicam que esses algoritmos não são adequados para a detecção de ataques de *spoofing* em VANTs.

Ao longo deste artigo o objetivo era buscar melhorar a eficiência do *Random Forest* comparado com o *XGBoost*, que ponderado com as métricas de performance foi o que obteve melhor eficiência no artigo de [Aissou et al. 2021]. Após os experimentos o objetivo foi alcançado com sucesso, através das técnicas de pré-processamento implementadas.

Apesar das métricas serem positivas, seria necessário melhorar as métricas de performance para que o algoritmo fosse viável para implementação em VANTs.

Em comparação ao artigo de [Aissou et al. 2021], o *Random Forest* obteve uma acurácia menor (93.51% contra 94.07%), o que indica que ainda há espaço para melhorar. Já o *XGBoost* obteve uma acurácia significativamente menor (79.29% contra 95.52%), indicando que as técnicas de pré-processamento utilizadas não foram eficazes para esse algoritmo. Portanto, é necessário explorar outras técnicas de pré-processamento ou ajustar os hiperparâmetros do modelo para melhorar seu desempenho. As probabilidades de detecção falsa e alarme falso do *Random Forest* foram de 9.24% e 1.63% respectivamente, enquanto no trabalho de [Aissou et al. 2021] foram de 3.77% e 8.53%. Isso indica que o *Random Forest* ainda pode ser melhorado para reduzir esses valores, aumentando a confiabilidade do modelo. Há a possibilidade que a escolha do *dataset* tenha influenciado negativamente nos resultados do *XGBoost*.

O algoritmo *Extremely Randomized Trees* não provou ser mais eficiente que o *Random Forest*, mas suas métricas de performance são ligeiramente melhores, sendo mais rápido no treinamento (6180.53 ms) e consumindo (10.12 MiB) de memória no treinamento e (18.13 MiB) na predição. O único ponto negativo é que é mais lento na predição (2237.85 ms). Portanto, seria uma alternativa viável ao *Random Forest*, pois no que diz respeito as métricas de desempenho os resultados são similares ao *Random Forest*.

7. Trabalhos Futuros

A dificuldade encontrada durante o desenvolvimento desse artigo foi escolher um método de pré-processamento eficaz para otimizar o *Random Forest*, porque estava desbalanceado o conjunto de dados utilizados.

Com base nessa dificuldade em trabalhos futuros seria interessante investigar o uso de outros algoritmos de aprendizado de máquina para detecção de ataques de *spoofing* de GPS, como por exemplo, redes neurais convolucionais (CNN) e inteligência artificial generativa, que tem se mostrado eficazes em outras aplicações. [Sun et al. 2023]; [El alami e Rawat 2024]

Realizar o *cross-validation* seria interessante, pois poderia fornecer uma avaliação mais robusta do desempenho dos modelos, evitando o overfitting e garantindo que os resultados obtidos sejam generalizáveis para novos dados.

Por fim, buscar a melhora do *Extremely Randomized Trees* pode ser um caminho viável e econômico em custos operacionais do que o *XGBoost* e o *Random Forest*.

Referências

- A. Faria¹, Lester de et al. (2018). “GPS Jamming Signals Propagation in Free-Space, Urban and Suburban Environments”. Em: *Journal Aerospace Technology Management*. DOI: 10.5028/jatm.v10.870.
- Aissou, Ghilas (2022). *A DATASET for GPS Spoofing Detection on Unmanned Aerial System*. Mendeley Data, V3. DOI: 10.17632/z7dj3yyzt8.3.
- Aissou, Ghilas et al. (2021). “Tree-based Supervised Machine Learning Models For Detecting GPS Spoofing Attacks on UAS”. Em: *2021 IEEE 12th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON)*, pp. 0649–0653. DOI: 10.1109/UEMCON53757.2021.9666744.
- Brasil, Dialogos Uniao Europeia (2025). *Estudo sobre a Indústria Brasileira e Europeia de Veículos aéreos não tripulados*. Rel. técn. Dialogos Uniao Europeia Brasil. DOI: https://www.gov.br/mdic/pt-br/images/publicacaoa_DRONES-20161130-20012017-web.pdf.
- El alami, Hassan e Danda B. Rawat (2024). “DroneDefGANt: A Generative AI-Based Approach for Detecting UAS Attacks and Faults”. Em: *ICC 2024 - IEEE International Conference on Communications*, pp. 1933–1938. DOI: 10.1109/ICC51166.2024.10622524. (Acesso em 23/07/2025).
- Geurts, Pierre, Damien Ernst e Louis Wehenkel (2006). “Extremely Randomized Trees”. Em: *Machine Learning* 63.1, pp. 3–42. ISSN: 0885-6125, 1573-0565. DOI: 10.1007/s10994-006-6226-1. URL: <http://link.springer.com/10.1007/s10994-006-6226-1> (acesso em 06/08/2025).
- Haghighi, Sepand et al. (2018). “PyCM: Multiclass confusion matrix library in Python”. Em: *Journal of Open Source Software* 3.25, p. 729. DOI: 10.21105/joss.00729. URL: <https://doi.org/10.21105/joss.00729>.
- İşleyen, Emre e Şerif Bahtiyar (2024). “GPS Spoofing Detection on Autonomous Vehicles with XGBoost”. Em: *2024 9th International Conference on Computer Science and Engineering (UBMK)*, pp. 500–505. DOI: 10.1109/UBMK63289.2024.10773593. (Acesso em 23/07/2025).

- Jafarnia-Jahromi, Ali, Ali Broumandan e Gérard Nielsen J. and Lachapelle (2012). “GPS Vulnerability to Spoofing Threats and a Review of Antispoofing Techniques”. Em: *International Journal of Navigation and Observation*. DOI: 10.1155/2012/127072.
- Japkowicz, Nathalie (2000). “Learning from Imbalanced Data Sets”. Em: *Proceedings of the AAAI Workshop on Learning from Imbalanced Data Sets*. AAAI Press.
- Jurman, Giuseppe, Samantha Riccadonna e Cesare Furlanello (2012). “A Comparison of MCC and CEN Error Measures in Multi-Class Prediction”. Em: *PLOS ONE* 7.8, pp. 1–8. DOI: 10.1371/journal.pone.0041882. URL: <https://doi.org/10.1371/journal.pone.0041882>.
- Panice, G. et al. (2017). “A SVM-based detection approach for GPS spoofing attacks to UAV”. Em: *2017 23rd International Conference on Automation and Computing (ICAC)*, pp. 1–11. DOI: 10.23919/ICAC.2017.8081999.
- Pearson, Karl (1894). “Contributions to the Mathematical Theory of Evolution”. Em: *Philosophical Transactions of the Royal Society of London. A* 185, pp. 71–110. DOI: 10.1098/rsta.1894.0003.
- (1901). “On Lines and Planes of Closest Fit to Systems of Points in Space”. Em: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2.11, pp. 559–572. DOI: 10.1080/14786440109462720.
- Srinivasan S, Prasanna e Shiju Sathyadevan (2023). “GPS Spoofing Detection in UAV Using Motion Processing Unit”. Em: *2023 11th International Symposium on Digital Forensics and Security (ISDFS)*, pp. 1–4. DOI: 10.1109/ISDFS58141.2023.10131729. (Acesso em 23/07/2025).
- Sun, Yichen et al. (2023). “A Deep-Learning-Based GPS Signal Spoofing Detection Method for Small UAVs”. Em: *Drones* 7.6. ISSN: 2504-446X. DOI: 10.3390/drones7060370. URL: <https://www.mdpi.com/2504-446X/7/6/370>.
- Titouna, Chafiq e Farid Naït-Abdesselam (2021). “A Lightweight Security Technique For Unmanned Aerial Vehicles Against GPS Spoofing Attack”. Em: *2021 International Wireless Communications and Mobile Computing (IWCMC)*, pp. 819–824. DOI: 10.1109/IWCMC51323.2021.9498734. (Acesso em 23/07/2025).